

DeerGuard

детектор AI-сгенерированных лиц

1. Актуальность и постановка задачи

Проект посвящён разработке системы автоматического обнаружения синтетических изображений лиц (deepfake-детекции), генерируемых архитектурами класса Generative Adversarial Networks (GAN). Актуальность обусловлена ростом угроз информационной безопасности, связанных с использованием синтетического контента в целях дезинформации, создания поддельных цифровых личностей и социальной инженерии.

Главная техническая трудность в задачах такого рода: кросс-генераторная генерализация. Модель, обученная на изображениях одного генератора, обычно цепляется за артефакты, характерные именно для него (это называют shortcut learning), и теряет точность на изображениях от других архитектур. Эта проблема оставалась центральной на протяжении всей работы над проектом.

2. История развития проекта

Проект прошёл несколько последовательных этапов, каждый из которых определялся результатами предыдущего и уточнял гипотезу о причинах провала генерализации.



Рисунок 1. Хронология развития проекта: от первичного исследования до финальной модели.

2.1. Этап 0. Первичное исследование (FaceForensics++)

Начальная стадия проекта строилась на датасете FaceForensics++ (с23) и была ориентирована на детекцию face-swap подделок. Этот этап позволил освоить базовые подходы к детекции манипуляций с лицами и подготовил почву для перехода к GAN-генерируемым изображениям.

2.2. Этап 1. Kaggle 140k StyleGAN2 и первая рабочая модель

На этом этапе использовался датасет Kaggle 140k Real and Fake Faces с изображениями, синтезированными StyleGAN2. Модель EfficientNet-B4 (v1) достигла AUC-ROC 1.0000 на тестовой выборке того же домена. Но при проверке на изображениях, сгенерированных более новыми архитектурами, точность резко падала: модель выучила артефакты конкретного генератора, а не общие признаки синтетичности изображения (то самое shortcut learning). Это заставило

переопределить центральную задачу проекта: дело не в улучшении архитектуры, а в диверсификации данных.

2.3. Этап 2. Архитектурные эксперименты

Для проверки гипотезы о том, что причина провала генерализации кроется в архитектуре, а не в данных, был проведён ряд контролируемых экспериментов с признаковыми представлениями входного изображения (см. Таблицу 2 в разделе 4).

Результат этой серии экспериментов оказался важным для дальнейшей стратегии: ни частотный анализ (FFT), ни стеганоаналитические SRM-фильтры не решили проблему обобщения сами по себе, без диверсификации обучающих данных. Это подтвердило гипотезу: корень проблемы в недостаточном разнообразии обучающей выборки, а не в ограниченности архитектуры.

2.4. Этап 3. Диверсификация датасета

На основе выводов предыдущего этапа стратегия проекта сместилась в сторону расширения обучающей выборки за счёт данных от нескольких генеративных архитектур. К исходным 30 000 изображениям StyleGAN2 последовательно добавили 7 100 изображений StyleGAN3, а затем около 7 500 изображений ProGAN. В итоге датасет включает три разных генератора.




Рисунок 2. Состав обучающего датасета по источникам после добавления ProGAN.

2.5. Этап 4. Методология CNNDetect и финальная модель

Одновременно с диверсификацией данных применена методология CNNDetect (Wang et al., CVPR 2020): обучение модели ResNet50 с агрессивной аугментацией посредством гауссова размытия и JPEG-компрессии переменного качества. Такой приём препятствует переобучению на артефактах, специфичных для конкретной генеративной архитектуры, и заставляет модель опираться на более общие признаки синтетичности изображения.

Комбинация методологической аугментации CNNDetect и мультигенераторного датасета (StyleGAN2 + StyleGAN3 + ProGAN) продемонстрировала статистически значимый прирост точности детекции на данных вне обучающего домена по сравнению с предыдущими подходами.

3. Данные

Итоговая обучающая выборка сформирована как объединение изображений реальных лиц и изображений, синтезированных тремя различными генеративными моделями, что обеспечивает кросс-генераторную генерализацию детектора.

Источник	Тип	Количество изображений
Kaggle 140k (реальные лица)	Real	30 000
StyleGAN2	Fake	30 000
StyleGAN3	Fake	7 100
ProGAN	Fake	~7 500
Итого Fake		44 600




Рисунок 3. Итоговое соотношение Real / Fake изображений в датасете.

4. Методология и архитектурные эксперименты

4.1. Базовая архитектура

В основе финальной системы лежит свёрточная нейронная сеть ResNet50, дообученная на бинарную задачу классификации (real / fake). Архитектуру выбрали из-за баланса между вычислительной эффективностью и способностью извлекать устойчивые признаки при использовании аугментации CNNDetect.

4.2. Сравнение экспериментальных конфигураций

В ходе разработки было опробовано несколько конфигураций входных признаков и аугментации. Таблица ниже отражает эволюцию архитектурных решений и качественные выводы по каждому эксперименту.

Конфигурация	Идея	Итог
Baseline RGB (EfficientNet-B4, 3 канала)	Обучение на сырых RGB-изображениях лиц без дополнительных признаков	AUC 1.0000 на StyleGAN2 (train domain), провал при доменном сдвиге
RGB + FFT (4 канала)	Добавление частотного канала (высокочастотные артефакты GAN)	Не решило проблему обобщения на практике, несмотря на теоретическую мотивацию
RGB + SRM (6 каналов)	Стеганоаналитические фильтры для выявления шумовых паттернов генерации	Аналогично FFT: без значимого улучшения генерализации
ResNet50 + CNNDetect-аугментация	Агрессивные blur + JPEG-компрессия переменного качества (Wang et al., CVPR 2020) + мультигенераторный датасет	Текущая рабочая модель: AUC-ROC 0.9999, Accuracy 99.7%

Примечание: точные значения AUC/Accuracy для промежуточных конфигураций (RGB+FFT, RGB+SRM) на кросс-доменной выборке отдельно не фиксировались. При необходимости их можно дополнить фактическими цифрами из логов экспериментов.

5. Ключевые находки

- Причина провала генерализации в shortcut learning на датасете одного генератора, а не в архитектурной или программной ошибке. Решение в диверсификации данных, а не в усложнении модели.
- Кросс-генераторная генерализация была центральной нерешённой проблемой проекта на момент начала работы. Все архитектурные эксперименты были вторичны по отношению к ней.
- Аугментация CNNDetect (Wang et al., CVPR 2020) теоретически обоснована для повышения кросс-генераторной устойчивости, и её практическая эффективность подтверждена на финальной модели.
- Частотные признаки (FFT, SRM) не решили проблему доменного сдвига на практике, несмотря на теоретическую мотивацию. Это важный отрицательный результат, ценный для научной новизны проекта.

6. Результаты

Финальная модель, ResNet50 с CNNDetect-аугментацией, обученная на объединённом мультигенераторном датасете (StyleGAN2, StyleGAN3, ProGAN), показывает следующие метрики качества на валидационной выборке:




Рисунок 4. Итоговые метрики качества модели.

Метрика	Значение
AUC-ROC	0.9999
Accuracy	99.7%
Обучающая выборка	30 000 real + 44 600 fake (StyleGAN2, StyleGAN3, ProGAN)
Архитектура	ResNet50, CnNDetect-аугментация (blur + JPEG)

7. Планы дальнейшего развития

Развитие проекта продолжается по следующим направлениям (в порядке приоритета):

- Валидация подхода CNNDetect (ResNet50 + агрессивная blur/JPEG-аугментация) на реальных, вне-доменных примерах. Код (train.py / detector.py) уже написан, тестирование в процессе.
- Дальнейшая диверсификация датасета: добавление изображений Stable Diffusion и face-swap подделок помимо GAN-генераторов.
- Визуализация Grad-CAM для интерпретируемости решений модели.
- Веб-интерфейс на FastAPI для демонстрации детектора в реальном времени.
- Ансамблевый детектор, объединяющий RGB-, частотный- и face-consistency-подходы.
- Расширение системы на видео- и аудио-дипфейки.